面向城市自动驾驶的基于 B 样条全局参考线与混合多边形避障的模型预测统一行为规划与运动控制

Model Predictive Unified Behavior Planning and Motion Control for Urban Autonomous Driving with B-Spline Global Reference Lines and Hybrid Polygonal Collision Avoidance

摘要：。

关键词：。

1 引言 INTRODUCTION

近年来，人工智能 (AI)、车联网 (V2X)、高精度地图以及车路协同等关键技术持续演进，使智能交通系统 (ITS) 向常态化应用迈进 [1–3]。自动驾驶被普遍视作推动道路交通智能化升级的重点，在提高通行效率的同时可以降低碰撞事故和能源消耗 [4–5]。尤其是在车流密集、参与者多样的城市道路，自动驾驶系统需要在实时约束下完成环境感知、周车行为预测、行为决策以及轨迹规划与控制等一系列任务，对系统整体框架与算法设计提出了高要求 [6]。

传统自动驾驶框架大多遵循“感知–预测–决策–规划–控制”流程，各个模块相对独立，通过设计接口与规则进行信息交互。这类分层架构在结构化高速路段或简单城市场景中表现较为可靠 [8]，但越来越多的研究指出：在路口交互、拥堵汇入和多车竞争等场景下，这种弱耦合模式容易引发问题 [9]：高层决策与下游规划/控制目标不一致，导致系统在行为选择与可行轨迹之间来回摇摆；预测层的不确定性信息难以系统传递到规划与控制层，极端工况下容易出现过度保守或反应延迟；各模块各自优化，整体上难以在安全性、效率与舒适性之间实现可解释的全局权衡。

为增强各子模块之间的一致性与协同性，近年来涌现出一系列基于模型的一体化的决策–控制框架，以模型预测控制 (MPC) 或有限时域最优控制问题 (OCP) 为核心，将行为决策、轨迹规划与车辆控制统一建模 [4]。此类方法通常在同一优化问题中同时考虑道路结构、交通规则、周车预测轨迹以及车辆动力学与约束，通过代价函数和约束的联合设计实现规则、安全、效率及舒适性的整体权衡。其中，Liu 等人提出 UDMC (Unified Decision-Making and Control) 框架，将周车运动预测、规则势场编码与控制输入作为统一优化问题的决策变量与约束项，实现了“预测–规则–控制”的紧耦合闭环 [11–12]。另一方面，面向多模态不确定性与强交互场景的两阶段优化、并行一致性优化以及博弈论一体化规划方法，则从不同角度探索了决策与控制的整体协同 [14–16]。

然而，当一体化框架被应用于真实城市道路时，其内部 OCP 往往呈现约束类型多、维度高以及非凸性强的特征。一方面，系统需要同时处理车道拓扑、速度限制、车距约束、信号灯与行人优先权等多种交通规则，还要兼顾乘坐舒适性与能耗；另一方面，与多车和行人相关的碰撞约束在几何上高度非凸，简单近似又容易带来过度保守。如何在有限算力下，以统一方式刻画规则与碰撞、安全与效率，并保证在线求解的收敛性与稳定性，是当前城市自动驾驶决策–控制研究的核心难点之一。

从建模角度看，现有一体化方法在以下四个方面仍存在不足：

(1) 全局参考路径平滑与局部优化的一致性。全局路径通常通过 A*、D* 等图搜索算法在道路拓扑上生成，再插值获得一条连续参考线 [19]。这类方法实现简单，但难以显式约束曲率，容易出现局部曲率尖峰，不仅影响跟踪舒适性，也会增加后续 OCP 的数值刚性 [20,21]。近年来，基于 B 样条或 Bézier 曲线的约束平滑方法，以及将曲率与边界约束写入 QP 的参考线平滑器被广泛应用于路径规划中 [22–25]，但如何在城市道路将这类“控制级”全局

参考线与下游统一 OCP 紧密耦合，仍缺乏系统研究。

(2) 交通规则与驾驶偏好的统一表达。大量工作尝试通过人工势场 (Artificial Potential Field, APF)、风险场等方式，将车道保持、限速、车距安全和障碍规避统一描述为势函数，以便在 MPC 或优化框架中处理 [27–29]。但在城市工况下，如何用结构统一、参数可调的势场同时表达“规则–安全–效率–舒适性”，并保证跨场景标定的可操作性，仍缺乏系统方案[30–36]。

(3) 碰撞约束的几何精度与可优化性。常用圆/椭圆对车辆与障碍物近似，以简化无碰撞约束 [37,38]，然而在车道狭窄、障碍形状复杂时保守性严重；直接使用多边形几何建模则容易引入混合整数规划，计算代价难以接受。基于强对偶理论的 Optimization-Based Collision Avoidance (OBCA) 及其 TDR-OBCA 扩展，在不使用整数变量的前提下实现了多边形碰撞约束的连续建模 [39]。基于风险轮廓和图上凸集的凸优化轨迹规划方法，也为在复杂障碍环境下构造安全可证轨迹提供了思路 [40,41]，但如何与城市中的规则约束和一体化 MPC 深度融合仍有待探索。

(4) 统一 OCP 的快速求解。 快速 MPC 与热启动 (warm start) 技术已在标准线性/弱非线性 MPC 中被广泛验证 [42–46]，但针对多层势场代价、多边形几何碰撞约束及周车预测的统一非凸 OCP，尚缺乏专门设计的混合求解与热启动策略。

尽管现有的统一决策控制框架 [11]在处理多模块协同方面展现了潜力，但其过度依赖势场来近似安全约束，导致在狭窄空间与强交互场景下，几何安全性与求解可行性之间难以权衡。为了克服传统基于势场的统一框架在几何精确性与求解效率上的局限，本文面向复杂城市道路场景，提出了一种基于 B 样条全局参考线与混合多边形避障的模型预测统一行为规划与运动控制框架 Model Predictive Unified Behavior Planning and Control（MP-UBPC）。该方法有机融合了约束 B 样条平滑、显式行为规则编码、基于对偶的多边形几何约束以及混合 QP 热启动策略。本文的主要贡献概括如下：

1) 提出基于约束 B 样条的全局参考线平滑方法。在 A* 拓扑路径之上构造以 B 样条控制点为决策变量的二次规划子问题，将各项要求统一写入代价函数和约束条件中，生成具有 C^2 连续性且曲率可控的全局参考线，为后续统一 OCP 提供更平滑的几何参考，改善一体化优化的收敛性与跟踪舒适性。
2) 建立显式参数化的行为规划规则层。 提出一套结构统一的规则势场编码机制，将车道保持、路权博弈及交通规则统一转化为低维特征向量，在统一优化问题中实现隐式的行为决策与规划，显著提升了对不同城市驾驶风格的适应性。
3) 提出混合多边形避障约束建模方法。 针对城市狭窄空间的精确避障挑战，利用凸优化强对偶理论，将复杂的凸多边形不相交几何条件重构为一组连续可微的代数约束。该方法通过引入非负松弛因子构建软硬协同机制，在消除圆盘近似保守性的同时，为非线性优化提供了高质量的梯度信息，显著提升了复杂环境下障碍物规避的几何精确性 。
4) 设计基于对偶初值复用的混合 QP 热启动一体化求解策略。针对含多边形碰撞约束和复杂势场代价的非凸 OCP，构造了基于一阶线性化动力学简化与多边形碰撞近似的凸 QP 预规划子问题。该策略通过在参考点处对非线性车辆动力学进行线性化简化，并配合障碍物半空间不等式近似局部可行域，快速生成局部可行的状态与控制序列。随后，将 QP 输出的原始变量作为主 NLP 的初值，加速主问题收敛并提升迭代稳定性。

The remainder of this paper is organized as follows. Section 2 reviews related work on global path planning, reference-line smoothing, unified decision–control frameworks, geometric collision-avoidance optimization, and warm-start strategies.

2 RELATED WORK

自动驾驶车辆在城市道路中的行为生成，涉及系统架构、一体化建模、规则与风险表达以及优化求解等多个方面。结合上一节问题分析，本节从四个方面对现有工作进行介绍。

A. Global Path Planning and Reference-Line Smoothing

在结构化道路环境中，全局路径规划通常在车道级拓扑图上进行。基于 A*、D* 及其改进算法的图搜索方法，能够在保证可达性的前提下高效求解起终点之间的最短路径或代价最小路径。但这类算法输出的往往是折线或分段圆弧序列，几何上存在曲率突变，难以直接作为车辆控制层的参考线。

为获得几何上连续且可跟踪的全局路径，许多工作在图搜索路径基础上引入样条或多项式平滑。早期方法多采用三次样条对离散节点进行插值，能够快速生成 C^2 连续曲线，但对曲率和曲率变化率缺乏显式约束，容易在路径拐角处产生较大的横向加速度峰值[19,20]。随后，B 样条和 Bézier 曲线因其良好的数值性质被广泛用于路径平滑与轨迹生成。Ravankar 等指出 B 样条、多项式轨迹和优化型光顺方法在考虑道路边界和动态约束时具有优势 [19]。Choi 等利用 B 样条生成同时满足曲率约束和连续转向的路径，实现了连续的路径平顺[21]。部分工作将 A* 等全局规划与 B 样条或高阶 B 样条平滑相结合，以同时兼顾路径最优性和跟踪舒适性[23,25]；也有工作将路径平滑显式建模为二次规划问题，通过对控制点或 Frenet 坐标下的偏移量进行优化，使平滑参考线在满足道路边界约束的同时最小化曲率和曲率变化 [19]。这些研究验证了在全局规划阶段引入带约束的样条平滑，有助于生成更适合下游 OCP 使用的“控制级”参考线。此外，Li 等提出的基于笛卡尔坐标的轨迹规划方法表明，在弯曲道路上避免 Frenet 坐标奇异性、直接在全局坐标系中约束几何形状，可以进一步提升规划结果与车辆动力学的一致性 [50]，这与本文采用 B 样条构造控制级全局参考线并在统一 OCP 中直接施加几何与曲率约束的思路一致。

B. Unified Decision–Control Frameworks

分层式架构是早期自动驾驶系统的主流设计范式，感知、预测、决策、规划与控制各自作为独立模块实现。这一架构在结构化高速路段具有较好工程可行性，但在多车交互与规则复杂的环境中，模块之间的“弱耦合”往往成为性能瓶颈。典型问题包括：决策层对下游几何约束与动态可行域考虑不足，规划层对上游风险偏好与策略不确定性感知不足，导致整体行为难以从全局角度兼顾安全性、效率与舒适性[3–5]。

为增强各模块间协同，基于 MPC 或有限时域 OCP 的一体化决策–控制框架逐步发展起来。相关方法通常直接以轨迹与控制序列为优化变量，将道路几何、交通规则、周车预测轨迹与车辆动力学统一写入约束与代价中[4,11]。Guan 等提出的 integrated decision and control 框架在同一优化层中联合建模决策逻辑与连续控制变量，在保证可解释性的同时显著压缩在线求解开销[51]；UDMC 框架则在同一优化层引入高斯过程或深度学习生成的周车运动预测与规则势场项，使预测结果与规则偏好通过统一目标函数与约束共同影响控制输出 [11–12]。在此基础上，Eiras 等提出的两阶段优化型城市驾驶运动规划器 [52] 和 Lim 等提出的混合采样﹣优化轨迹规划框架 [53]，通过先粗规划后精细优化分解高维优化问题，与并行一致性优化等方法[14-16]，共同体现了在统一模型中兼顾可行性与实时性的思路。另一方面，Aasi 等 [54] 提出两层 MPC 框架，将交通规则用信号时序逻辑（Signal Temporal Logic, STL）表达并转化为混合整数约束，形成混合整数二次规划（Mixed-Integer QP, MIQP）问题；下层负责仿真监控并在违规时反馈校正约束。该类形式化方法刻画规范更严格，但在复杂城市场景中对混合整数求解的依赖可能带来较高在线计算压力。

与基于模型的一体化方法相对，端到端 (end-to-end) 控制策略通过单一深度网络直接从多模态感知输入生成控制输出，在 CARLA 等仿真平台上取得了较高的通行率和鲁棒性 [47–49]。但目前端到端方法在规则显式约束、行为可解释性以及安全可证性方面仍面临障碍 [9]，因而更广泛应用的路径是利用学习辅助模块改进可解释的一体化优化框架的混合架构。

C. Potential-Based Rule Modeling and Local Planning

针对交通规则与局部安全的建模需求，势场与风险场方法提供了成本较低、结构直观的手段。APF 类方法通过为目标区域和障碍物构造势函数，使优化问题或控制律在吸引与排斥平衡下生成轨迹。Rasekhipour 等将 APF 与动力学 MPC 结合，将车道中心、道路边界与障碍物分别编码为不同势函数，实现了在满足车辆动力学约束条件下

的局部路径规划 [27]；后续工作通过在势函数中引入相对速度、时间头距等动态信息，提高对碰撞风险随时间变化的刻画能力 [29]。

随着研究扩展到城市道路，APF 被广泛与采样/搜索规划和学习方法结合使用。改进 APF 在势函数形状与参数自适应，减轻了经典 APF 的局部极小与振荡问题，并在城市道路路径生成中提升了路径质量与收敛效率 [29]；APF–RRT*、APF 加动态运动基元等方法通过利用势场引导搜索或轨迹基元选择，兼顾探索性与引导性[30]。风险场将多车交互和环境不确定性整合进势场中。相关研究通过将相对位置、速度等因素映射为时空风险标量，构建局部风险场实现行车风险评估 [32,33]；部分工作将预测模型与风险场结合，先由深度网络估计目标车未来运动，再根据预测结果生成前向风险场并据此规划安全路径 [34,35]；也有工作将改进 APF 与风险场结合，用于复杂障碍环境中的风险规避路径规划 [36]。用势场/风险场统一编码规则与风险，并与 MPC 或优化规划联合使用，是在复杂场景中平衡规则与安全的有效手段。

目前多数 APF/风险场针对特定规则或场景单独设计势函数，难以直接在一体化 OCP 中以统一且低维的方式同时表达车道、速度、车距、信号与行人等多种约束。规则层在参数可调性与场景迁移方面仍存在不足。

D. Geometric Collision Modeling and Fast MPC

在复杂城市环境中，碰撞规避约束是统一决策–控制问题的核心组成部分。传统方法多用圆盘或椭圆近似车辆与障碍物，并通过安全距离约束实现无碰撞，虽然形式简单且易于构造凸约束，但在道路狭窄或障碍形状复杂时保守性较强。多边形或多凸集几何表达可显著改善这一问题，却往往需引入混合整数规划，计算复杂度难以满足车规级实时性要求。

OBCA 基于凸优化强对偶理论提出了一种连续建模多边形碰撞约束的方法：通过对偶变量刻画凸多边形之间存在分离超平面的条件，将几何不相交约束转化为一组连续等式/不等式 [37,38]。TDR-OBCA 进一步通过时间分解、对偶变量热启动和代价重构等手段提升了规划器在开阔空间中的鲁棒性与求解效率，并得到实践检验 [39]。与此同时，基于风险轮廓、图上凸集和半定规划的轨迹规划方法，将复杂障碍环境与概率安全约束转化为凸优化问题，在无人机重规划与地面机器人避障中展示出良好的性能 [40,41]。

从求解角度看，包含多边形几何碰撞约束与复杂势场代价的一体化 OCP 高度非凸，若完全依赖通用非线性规划求解往往难以满足实时性。快速 MPC 通过利用问题结构与热启动技术，复用上一时刻的最优解、主动集或对偶信息，已经在标准线性与部分非线性问题上验证了其减少迭代次数与缩短计算时间的有效性 [42,43]。近年来也出现了用学习方法预测 QP 初始解或主动集结构的工作，以进一步压缩求解时间 [44–46]。不过，针对多层规则势场、多边形几何碰撞及预测驱动的统一决策–控制问题，如何在保证安全约束与几何精度的同时设计高效的混合解算与热启动策略，仍然是开放问题。

E. Summary

综上所述，一体化决策–控制框架、势场规则建模、多边形几何碰撞建模以及快速 MPC 求解等方向，为城市自动驾驶提供了坚实的方法基础；端到端驾驶、经典 MPC 理论、安全包络与 Safety Force Field 等研究，则从学习、控制和安全分析等角度提供了重要补充。然而，在复杂城市道路场景下，如何在统一优化框架中同时实现交通规则的显式建模、精细的几何安全约束以及面向在线应用的求解效率，仍缺乏系统而成熟的解决方案。本框架整合了约束 B 样条参考线平滑、显式行为规则编码、基于对偶的多边形硬约束以及混合 QP 热启动策略。旨在保留统一建模优势的同时，在行为的可解释性、几何建模精度与实时求解效率之间实现更优的权衡。

3. PRELIMINARIES

A. 车道级拓扑建模

本文考虑的环境为结构化城市道路场景，包括 xxx 场景等。道路网络在高精地图中可抽象为一张有向图 $\mathcal{G}=(\mathcal{V},\mathcal{E})$，其中节点集合 $\mathcal{V}=\{v_i\}$，表示车道中心线上的离散参考点或路口虚拟节点，边集合 $\mathcal{E}\subseteq\mathcal{V}\times\mathcal{V}$ 表示沿车道前进、转向或变道的可行拓扑连接。对每条有向边 $e=(v_i,v_j)\in\mathcal{E}$，关联一组属性 $c(e)=(L_e,v_{\max,e},\text{type}_e,\Gamma_e)$，其中 L_e 为该车道段中心线长度，$v_{\max,e}$ 为该段车道的限速，type_e 用于区分直行、左转、右转或变道边，Γ_e 描述该车道段对应的道路几何可行域。

在全局路径规划阶段，给定起点节点 v_s 与终点节点 v_g，在图 $\mathcal{G}$ 上通过 A*等启发式算法搜索得到一条车道级最优路径 $\pi^{A^*}=\{e_k\}_{k=0}^{M-1}$，并最小化包含距离、限速与路口惩罚在内的全局代价函数：

$$J_{\text{global}}=\sum_{k=0}^{M-1}\left(w_L L_{e_k}+w_v\phi_v(e_k)+w_c\phi_c(e_k)\right) \tag{1}$$

其中 L_{e_k} 是边 e_k 的几何长度，$e_k=(v_{i_k},v_{i_{k+1}})$，$k\in(0,1,...,M-1)$，$\phi_v(e_k)$，$\phi_c(e_k)$ 分别描述限速违背代价和路口类型、变道次数的附加代价，w_L,w_v,w_c 为权重参数。

将得到的车道级 A*路径映射到几何空间，可得到一组二维离散路径点：

$$\mathcal{P}^{A^*}=\{p_j=(x_j,y_j)^\top\in\mathbb{R}^2\mid j=0,\dots,N_p\} \tag{2}$$

构成一条由折线段或圆弧拼接而成的粗参考线。高精地图还提供与每个路径点 p_j 对应的车道切向方向、车道宽度及左右边界，可形式化为一对隐式边界函数：

$$\mathcal{R}_j^L=\left\{(x,y)\in\mathbb{R}^2\middle|h_j^L(x,y)\le 0\right\},\quad \mathcal{R}_j^R=\left\{(x,y)\in\mathbb{R}^2\middle|h_j^R(x,y)\le 0\right\} \tag{3}$$

其中 $h_j^L(\cdot),h_j^R(\cdot)$ 用于描述左右车道边界。沿着参考线，将相邻路径点处的左右边界连通并放宽，可在每个预测步 k 定义道路可行区域 $\mathcal{R}_{\text{road}}(k)\subset\mathbb{R}^2$。

B. 周车运动预测模块

针对动态障碍物几何约束的构建需求，本文采用基于高斯过程回归（IGPR）的方法对周车运动进行建模 [11]。该模块的核心思想是以短时历史轨迹为输入，结合车道结构与交互特征，生成未来时域内的平滑预测轨迹分布，从而为统一优化问题提供显式的障碍物状态参考。设第 i 辆周车在当前时刻 j 的状态为

$$\xi_i(t)=\left[x_i(t),y_i(t),v_i(t),\psi_i(t)\right]^{\mathrm{T}} \tag{4}$$

其中 (x_i,y_i) 为全局坐标，v_i 为速度，ψ_i 为航向角。IGPR 使用长度为 N_{obs} 的历史样本窗口作为训练集。对每个历史时刻 t_n 构造输入向量：

$$z_{i,n}=\left[\xi_i(t_n),\chi_n\right]^{\mathrm{T}},\quad n=1,\dots,N_{\text{obs}} \tag{5}$$

其中 χ_n 包含车道 ID、相对位置、信号灯状态等场景特征。对应输出 $y_{i,n}$ 为待预测状态分量或其增量。对每个

周车i，假设存在潜在函数$f_i(\cdot)$，并服从零均值高斯过程先验：

$$f_i(z)\sim\mathcal{GP}\big(0,k(z,z')\big) \tag{6}$$

其中核函数为平方指数形式：

$$k(z,z')=\sigma_f^2\exp\Big(-\tfrac{1}{2}(z-z')^\top\Lambda^{-1}(z-z')\Big) \tag{7}$$

其中$\Lambda=\mathrm{diag}(\ell_1^2,\ldots,\ell_d^2)$为尺度矩阵，$\sigma_f^2$为空间方差。

给定训练集合$\mathcal{D}_i=\{(z_{i,n},y_{i,n})\}_{n=1}^{N_{\mathrm{obs}}}$，定义核矩阵

$$K_{mn}=k(z_{i,m},z_{i,n}),\quad m,n=1,\ldots,N_{\mathrm{obs}} \tag{8}$$

观测噪声方差为σ_n^2，对预测输入$z_*=z_i(\tau\mid t)$，其后验均值和方差为：

$$\mu_i(z_*)=k_*^\top(K+\sigma_n^2 I)^{-1}\mathbf{y}_i \tag{9}$$

$$\sigma_i^2(z_*)=k(z_*,z_*)-k_*^\top(K+\sigma_n^2 I)^{-1}k_* \tag{10}$$

其中$k_*=[k(z_*,z_{i,1}),\ldots,k(z_*,z_{i,N_{\mathrm{obs}}})]^\top$，$\mathbf{y}_i=[y_{i,1},\ldots,y_{i,N_{\mathrm{obs}}}]^\top$。在每个控制周期$t$，对预测时域内各离散时间步$k=1,\ldots,N$的输入$z_*(k\mid t)$重复上述计算，即可得到周车集合$\mathcal{I}$的预测轨迹：

$$\hat{\xi}_i(k\mid t)_{i\in\mathcal{I},k=1,\ldots,N} \tag{11}$$

预测模块与统一 OCP 的耦合主要体现在在代价函数中，引入基于预测轨迹的规则势场或风险势场项，用以度量自车与周车在时空上的交互风险；在约束中，将预测轨迹及其不确定性用于构造安全距离约束或碰撞规避约束。本文在保持IGPR模块结构与接口不变的前提下，仅在统一OCP内部重构规则势场、道路几何与碰撞约束的形式，使预测结果$\hat{\xi}_i(k\mid t)$可以通过更精细的几何与势场建模进入优化问题。为了显式利用预测模块输出的方差$\sigma_{i,k|t}^2$以应对感知与预测不确定性，本文引入基于方差的动态安全裕度膨胀机制：定义膨胀后的安全距离为$d_{safe,i,k}=d_{base}+\eta\sigma_{i,k|t}$，其中$d_{base}$为车辆间的基础安全距离，$\eta$为风险敏感度调节系数。该机制使得在预测不确定性较高的时空区域，避障约束会自动变得更加保守，从而保证了决策的概率安全性。

C. 车辆动力学模型与控制约束

为准确描述车辆在城市道路复杂工况下的动力学可行性，并避免低速计算时的奇异性，本文采用了文献[55]提出的数值稳定的非线性 6 维车辆动力学建模形式。定义状态向量和控制输入为：

$$\mathbf{x}(t)=\big[x(t),y(t),\psi(t),v_x(t),v_y(t),\omega(t)\big]^{\mathrm{T}},\quad \mathbf{u}(t)=\big[a(t),\delta(t)\big]^{\mathrm{T}} \tag{12}$$

其中(x,y)为全局坐标系下质心位置，ψ为航向角，v_x,v_y为车体坐标系下纵向与横向速度，ω为偏航角速度，a为纵向加速度控制输入，δ为前轮转角。

在小转角和中等侧偏角条件下，车辆动力学可写为连续形式:

$$
\begin{aligned}
\dot{x} &= v_x \cos\psi - v_y \sin\psi \\
\dot{y} &= v_x \sin\psi + v_y \cos\psi \\
\dot{\psi} &= \omega \\
\dot{v}_x &= a + v_y \omega \\
\dot{v}_y &= \frac{1}{m}(F_{yf} + F_{yr}) - v_x \omega \\
\dot{\omega} &= \frac{1}{I_z}(l_f F_{yf} - l_r F_{yr})
\end{aligned}
\tag{13}
$$

其中 m 为整车质量，I_z 为绕垂直轴转动惯量，l_f, l_r 分别为前、后轴到质心的距离， 前、后轮的横向力 F_{yf}, F_{yr} 采用线性轮胎模型：

$$
\begin{aligned}
\beta &= \arctan\left(\frac{v_y}{v_x}\right) \\
F_{yf} &= -C_f\left(\beta + \frac{l_f \omega}{v_x} - \delta\right) \\
F_{yr} &= -C_r\left(\beta - \frac{l_r \omega}{v_x}\right)
\end{aligned}
\tag{14}
$$

其中 C_f ,C_r为前、后轮侧偏刚度。

为满足实时性要求，采用前向欧拉法保持离散化，以采样时间 T_s 得到离散时间模型：

$$
\mathbf{x}_{k+1} = f\left(\mathbf{x}_k, \mathbf{u}_k\right), \quad k = 0,1,\ldots n \tag{15}
$$

其中 $f(\cdot,\cdot)$ 表示离散时间非线性状态转移函数。为进一步提高求解效率，在每个采样周期内围绕参考轨迹对非线性模型进行一阶线性化，得到：

$$
\Delta\mathbf{x}_{k+1} = \mathbf{A}_k \Delta\mathbf{x}_k + \mathbf{B}_k \Delta\mathbf{u}_k \tag{16}
$$

其中 $\Delta\mathbf{x}_k = \mathbf{x}_k - \mathbf{x}_k^{\text{ref}}$， $\Delta\mathbf{u}_k = \mathbf{u}_k - \mathbf{u}_k^{\text{ref}}$， $\mathbf{A}_k, \mathbf{B}_k$ 为在参考点处的雅可比矩阵。

为了确保规划轨迹在物理层面的可行性与安全性，控制输入和状态变量受到以下约束：

$$
\begin{aligned}
a_{\min} &\le a_k \le a_{\max} \\
\delta_{\min} &\le \delta_k \le \delta_{\max} \\
v_{x,\min} &\le v_{x,k} \le v_{x,\max} \\
|\omega_k| &\le \omega_{\max}
\end{aligned}
\tag{17}
$$

如式 (17) 所示，约束涵盖了执行器的响应范围（纵向加速度 a_k 与前轮转角 δ_k ）以及车辆动力学稳定性要求（纵向速度 $v_{x,k}$ 与偏航角速度 ω_k ）上述约束与道路限速、车道几何进一步组合成状态约束集合 $\mathcal{X}$ 与控制约束集合 $\mathcal{U}$，用于统一 OCP 建模。

D. Problem Formulation

统一决策控制框架（Unified Decision–Control Frameworks）通常将城市自动驾驶任务建模为有限时域 OCP，在同一优化层中联合考虑参考轨迹跟踪、车辆动力学约束和基于势场的交通规则编码 [11]。其核心思想是：以预测时域内的状态–控制序列为决策变量，通过代价函数和约束统一刻画安全性、效率与舒适性。本文考虑的城市自动驾驶任务可以表述为如下时变有限时域最优控制问题：

设预测时域长度为 N，在当前时刻 t 上构造状态与控制序列

$$\mathbf{X}_t = \{\mathbf{x}_{k|t}\}_{k=0}^{N}, \quad \mathbf{U}_t = \{\mathbf{u}_{k|t}\}_{k=0}^{N-1} \tag{18}$$

其中 $\mathbf{x}_{k|t}$ 表示在时刻 t 优化得到的第 k 步的预测状态，$k \in (0,1...N)$。

在每个控制周期 t，给定当前自车状态 $\mathbf{x}(t)$，全局参考轨迹 $\{\mathbf{x}_k^{\text{ref}}\}_{k=0}^{N}$，周车预测轨迹 $\hat{\xi}_i(k|\ t)_{i\in\mathcal{I},k=1,\dots,N}$，离散动力学模型 $\mathbf{x}_{k+1} = f(\mathbf{x}_k, \mathbf{u}_k)$，以及道路可行区域 $\mathcal{R}_{\text{road}}^{\text{Bspline}}(k)$，求解预测状态与控制序列 $\mathbf{X}_t$, $\mathbf{U}_t$ 与几何碰撞建模相关的对偶变量集合 $\mathbf{\Lambda}_t = \{(\lambda_{i,k|t}, \mu_{i,k|t}, s_{i,k|t}) | \ k=0,..,N, i\in\mathcal{I}\}$，其中 $\lambda_{i,k}, \mu_{i,k}$ 为将非凸几何约束转化为平滑代数约束引入的拉格朗日对偶变量，$s_{i,k}$ 为确保求解可行性的非负松弛变量。

优化目标是使得综合性能指标在满足动力学、几何和安全约束的条件下取得最小。统一代价函数由参考跟踪项、控制能量与平滑项以及规则势场项组成，可写为：

$$\begin{aligned} J_t(\mathbf{X}_t, \mathbf{U}_t, \mathbf{\Lambda}_t) = \sum_{k=0}^{N-1} \Big(\| \mathbf{x}_{k|t} - \mathbf{x}_k^{\text{ref}} \|_{\mathbf{Q}_x}^2 + \| \mathbf{u}_{k|t} \|_{\mathbf{R}_u}^2 + \| \mathbf{u}_{k|t} - \mathbf{u}_{k-1|t} \|_{\mathbf{R}_\Delta}^2 \Big) + \\ \| \mathbf{x}_{N|t} - \mathbf{x}_N^{\text{ref}} \|_{\mathbf{P}}^2 + \sum_{k=0}^{N} \Phi_{\text{rule}} \Big(\mathbf{x}_{k|t}, \big\{ \hat{\xi}_i(k|\ t) \big\}_{i\in\mathcal{I}} \Big) + w_{slack} \sum_{i\in\mathcal{I}} \sum_{k=0}^{N} s_{i,k|t}^2 \end{aligned} \tag{19}$$

其中 $\mathbf{x}_k^{\text{ref}}$ 为沿全局参考线生成的几何与速度参考，$\mathbf{Q}_x, \mathbf{R}_u, \mathbf{R}_\Delta, \mathbf{P}$ 为权重矩阵，$\mathbf{Q}_x, \mathbf{R}_u$ 分别用于刻画状态跟踪误差与控制能量代价，$\mathbf{R}_\Delta$ 用于抑制控制变化，$\mathbf{P}$ 用于终端误差惩罚；终端项通过对 $\mathbf{x}_{N|t}$ 与 $\mathbf{x}_N^{\text{ref}}$ 的偏差施加二次惩罚，实现一种软终端约束机制，用于抑制滚动优化导致的终点漂移并提升轨迹在有限时域内的收敛一致性。$\Phi_{\text{rule}}(\cdot)$ 为规则势场项，将车道保持、限速、车距安全与路权偏好等规则因素统一编码为可微的标量惩罚。

综合动力学约束、控制与状态边界、道路几何约束以及基于多边形几何构造的碰撞约束，统一决策–控制 OCP 形式化为：

$$\begin{aligned} \min_{\mathbf{X}_t, \mathbf{U}_t, \mathbf{\Lambda}_t} \quad & J(\mathbf{X}_t, \mathbf{U}_t, \mathbf{\Lambda}_t) \\ \text{s.t.} \quad & \mathbf{x}_{0|\ t} = \mathbf{x}(t), \\ & \mathbf{x}_{k+1|\ t} = f(\mathbf{x}_{k|\ t}, \mathbf{u}_{k|\ t}), && k = 0,...,N-1 \\ & \mathbf{x}_{k+1|\ t} \in \mathcal{X}, && k = 0,...,N-1 \\ & \mathbf{u}_{k|\ t} \in \mathcal{U}, && k = 0,...,N-1 \\ & p_{k|t} \in \mathcal{R}_{\text{road}}^{\text{Bspline}}(k), && k = 0,...,N \\ & \mathcal{C}_{\text{poly}}(\mathbf{x}_{k|t}, \{\hat{\xi}_i(k|t)\}, \lambda_{i,k|t}, \mu_{i,k|t}, s_{i,k|t}) \le 0, && \forall i \in \mathcal{I}, k = 0,...,N \end{aligned} \tag{20}$$

其中 $p_{k|t}$ 表示自车在全局坐标系下的质心位置坐标，$\mathcal{C}_{\text{poly}}(\cdot) \le 0$ 表示基于凸多边形几何的硬避障约束集合。该约束通过引入对偶变量将几何不相交条件转化为可微的代数不等式，用于保证自车在预测时域内与周车及静态障碍物保持安全几何关系。

该优化问题给出了本文决策–控制任务的形式化描述：在给定地图、参考线、周车预测和动力学约束的条件下，通过求解约束优化问题获得一条在预测时域内满足道路约束、碰撞约束及输入/状态约束的最优控制序列。

4. PROPOSED METHOD

本章在第 3 章建立的系统模型与问题描述基础上，详细阐述本文提出的 MP-UBPC 框架。本框架从全局参考线几何、交通规则编码、几何碰撞约束以及求解策略四个核心维度出发，构建了一套基于约束 B 样条平滑与混合多边形避障的系统化解决方案。通过这四个层面的协同设计，MP-UBPC 能够在复杂的城市道路场景下，有效解决软硬约束的耦合难题，从而在安全性、效率、舒适性和实时性之间取得更优的平衡。

A. 总体架构

在统一 OCP 建模思想的基础上，本文围绕城市道路场景的几何特性与规则复杂性，对 OCP 中的关键组成部分进行了四个层面的扩展与重构：

1. 全局参考线层：在 A* 拓扑路径基础上，引入约束 B-spline 平滑模块，将离散路网路径转化为具有良好曲率特性的光滑参考线，并由此定义更精细的道路走廊约束 $\mathcal{R}_{\text{road}}^{\text{Bspline}}(k)$，为下游优化提供高质量的几何基准。

2. 规则势场层：重新定义车道保持、限速、跟车安全、交通信号与行人礼让等势函数族，构造一套物理含义清晰的统一势场表示 $\Phi_{\text{rule}}\left(\mathbf{x}_{k|t}, \{\hat{\xi}_i(k|t)\}; \theta_{\text{rule}}\right)$。该层作为隐式的行为规划器，负责处理交通规则与路权博弈，并能够与底层的硬碰撞约束协同工作。

3. 几何碰撞约束层：将原先以距离或势场近似的软碰撞代价，重构为基于多边形几何的连续约束集合 $\mathcal{C}_{\text{poly}}$，通过引入对偶变量集合 (λ, μ) 与松弛因子 s 针对静态障碍物与动态周车构造凸多边形分离条件，在不引入整数变量（MILP）的前提下消除了几何建模的保守性。

4. 求解与热启动层：针对包含多边形硬约束的非凸 OCP，建立分层求解架构，在主 NLP 优化层之上增加一层凸 QP 预规划模块，利用简化动力学与顶点-半空间线性化近似快速生成局部安全轨迹，并将其作为非线性 MPC 的初始解，从而在保证几何精确性的同时大幅降低平均求解时间。

结合上述关键模块，本文提出的模型预测统一行为规划与运动控制（Model Predictive Unified Behavior Planning and Motion Control, MP-UBPC）框架如图 4 所示，整体控制流程可概括为：感知和地图模块提供车道拓扑、A* 粗路径和静态环境信息，IGPR 等预测模块输出周车预测轨迹；约束 B-spline 模块生成“控制级”的全局参考线与车道走廊；规则势场和多边形约束模块在统一 OCP 内部编码交通规则与几何安全；混合 QP 热启动模块为主 MPC 提供高质量初始解，最终求解得到当前控制输入 $u(t)$，并按 receding horizon 方式滚动执行。

B. 约束 B-spline 全局参考线平滑

1) B-spline 参数化与二次代价

全局路径由 A* 算法在车道级拓扑图上搜索得到，输出的路径点集为 $\mathcal{P} = \{p_j\}_{j=0}^{M-1}$，其中 $p_j = (x_j, y_j)^\top$，刻画了起终点之间的拓扑连通关系及车道级行驶意图。对于高层行为决策而言，这条“折线路径”已经足以描述“从哪条路走到哪条路”；但对于依赖梯度信息的 MPC/OCP 来说，折线轨迹在曲率连续性及数值平滑性方面存在明显不足，容易导致拐角区域横向加速度和转向角的尖峰，并增加统一 OCP 的数值刚性。

为此，本文在 A* 输出路径的基础上，通过二维 B-spline 对离散路径进行平滑。设沿粗路径的弧长参数为 $\{s_j\}_{j=0}^{M-1}$。选取 n_c 个二维控制点 $\{\mathbf{c}_\ell\}_{\ell=0}^{n_c-1}$，其中 $\mathbf{c}_\ell = (c_\ell^x, c_\ell^y)^\top$。在给定节点向量与 B-spline 基函数 $B_\ell(s)$ 的情况下，全局参考线可写为：

$$r(s) = \begin{bmatrix} x(s) \\ y(s) \end{bmatrix} = \sum_{\ell=0}^{n_c-1} B_\ell(s)\mathbf{c}_\ell \tag{21}$$

可以看到，路径坐标 $r(s)$ 相对于控制点向量 $C = [\mathbf{c}_0^\top, \dots, \mathbf{c}_{n_c-1}^\top]^\top$ 是线性的，这为后续将平滑问题表达为二次规划提供了结构基础。

在目标函数设计上，本文在尽量贴合 A* 原始路径和几何形状足够平顺之前平衡。一方面，通过在弧长采样点 $\{s_j\}$ 上惩罚拟合误差：

$$J_{\text{fit}} = \sum_{j=0}^{M-1} \| r(s_j) - p_j \|_2^2 \tag{22}$$

可以保证平滑后的参考线在整体上保持原有的路径拓扑与几何趋势。另一方面，通过控制点二阶差分构造光顺代价：

$$J_{\text{smooth}} = \sum_{\ell=0}^{n_c-3} \| \mathbf{c}_{\ell+2} - 2\mathbf{c}_{\ell+1} + \mathbf{c}_{\ell} \|_2^2 \tag{23}$$

在离散意义上抑制曲率的高频变化，从而避免在路口或急弯位置产生过大的曲率脉冲。两者加权叠加得到 B-spline 平滑的二次目标函数：

$$J_{\text{bs}}(C) = w_{\text{fit}} J_{\text{fit}} + w_{\text{smooth}} J_{\text{smooth}} \tag{24}$$

其中 $w_{\text{fit}}, w_{\text{smooth}}$ 为对应的权重。由于式(22)–(24) 对控制点向量 C 均为二次形式，整体优化问题可以自然写成标准 QP，为后续引入约束并使用稀疏 QP 求解器奠定了基础。

2) 车道边界与曲率约束

仅通过拟合与光顺项并不足以保证参考线在道路几何上的可行性。依托高精地图可获得的车道中心、左右边界和限速信息，本文将车道边界与曲率限制显式写入 B-spline 平滑的约束集合中。

记第 j 个采样点处车道中心为 $r_{cen}(s_j)$，单位法向量为 $n(s_j)$，左、右边界到中心线的距离分别为 $d_{\text{L}}(s_j), d_{\text{R}}(s_j)$。平滑参考线在该截面的横向偏移定义为 $d(s_j) = n(s_j)^{\top}(r(s_j) - r_{\text{cen}}(s_j))$，通过限制该偏移量位于边界内侧减去横向安全裕度 δ_{safe} 的区间，可以保证参考线在整个路径上始终位于车道走廊内部：

$$-d_{\text{L}}(s_j) + \delta_{\text{safe}} \le d(s_j) \le d_{\text{R}}(s_j) - \delta_{\text{safe}}, \quad j = 0, \ldots, M-1 \tag{25}$$

由于 $r(s_j)$ 是控制点的线性组合，上式在 C 上对应一组线性不等式约束，数值性质良好。

为保证参考线的几何平滑性并满足车辆运动学限制，需对路径曲率 $\kappa(s)$ 进行约束。对于 p 阶均匀 B 样条曲线 $r(s) = \sum_l B_{l,p}(u)\mathbf{c}_l$，其二阶导数与控制点的二阶差分正相关。为避免非线性曲率公式 $\kappa = \frac{|x'y'' - y'x''|}{(x'^2 + y'^2)^{3/2}}$ 破坏优化问题的凸性，本文采用控制点的二阶差分范数来线性化曲率约束。在假设参考线近似为弧长参数化且节点间距均匀的前提下,对于任意三个连续控制点 $\mathbf{c}_l, \mathbf{c}_{l-1}, \mathbf{c}_{l+1}$，其二阶差分模长近似于路径二阶导数，从而与曲率成正比。因此，我们将曲率受限于最小转弯半径 R_{min} 的非线性约束，松弛为关于控制点的凸二次约束：

$$\| \mathbf{c}_{l+1} - 2\mathbf{c}_l + \mathbf{c}_{l-1} \| \le \kappa_{max} \Delta_s^2 \tag{26}$$

其中 $\kappa_{max} = 1/R_{min}$ ，Δs 为节点的平均弧长间距。该约束限制了控制点多边形的尖锐程度，从而在保证 C^2 连续性的同时，确保生成的参考线曲率处处有界。从而将平滑问题建模为标准的二次规划 (QP) 问题，保证了全局最优解的快速获取。

综合拟合代价、光顺代价、车道边界约束和曲率约束，B-spline 平滑问题最终写为：

$$\begin{aligned} \min_{C} \quad & J_{\text{bs}}(C) \\ \text{s.t.} \quad & \text{boundary constraints (25)}, \\ & \text{curvature constraints (26)}, \\ & c_0 \approx p_0, c_{n_c-1} \approx p_{M-1}. \end{aligned} \tag{27}$$

其中首末约束保证平滑曲线在起终点处与 A* 路径保持一致。该问题为凸 QP，可在仿真开始前离线求解，也可在全局路径更新时低频率在线求解，获得最优控制点 $C^{\star}$ 。由此生成的参考线 $r(s)$ 及其对应的道路走廊区域 $\mathcal{R}_{\text{road}}^{\text{Bspline}}(k)$ 在统一 OCP 中被用作几何约束，使后续规则势场和碰撞约束都建立在一个几何性质可控的“控制级”参考

线上。

C. 规则势场层

Liu 等人[11]利用人工势场将部分交通规则与安全偏好编码到统一 OCP 的代价函数中，构造一组具有明确物理含义的势函数，并在 MPC 的滚动优化过程中以连续代价的形式引导系统行为，使车辆在满足约束的同时展现出符合人类驾驶直觉的决策模式。在城市道路场景下，交通规则种类更多、相互关系更加复杂，行人与信号灯等参与者也显著增多。若势函数的设计与参数化缺乏统一结构，则在不同场景间迁移时容易面临调参困难、行为风格难以系统控制等问题。

本文在现有基于势场的建模思想基础上，对规则势场层进行了统一建模与显式参数化重构。具体而言，在预测步 k 下，规则相关代价统一写成若干基本势函数的加权和，涵盖车道保持与姿态一致性、速度与舒适性、车距与时间到碰撞（time-to-collision, TTC）、行人礼让以及交通信号遵守等多个方面。所有势函数在每一预测步可组合为特征向量，所有权重及超参数收集为向量。从而规则层代价简洁表示，形成一套低维、结构统一且物理含义清晰的参数化规则层。

在预测步 k 下，规则相关代价统一写成势函数族的加权和：

$$\Phi_{\text{rule}}\left(\mathbf{x}_{k|\,t},\{\hat{\boldsymbol{\xi}}_i(k|\,t)\}_{i\in\mathcal{I}};\theta_{\text{rule}}\right)=\sum_{p\in\mathcal{P}} w_p\,\phi_p\left(\mathbf{x}_{k|\,t},\{\hat{\boldsymbol{\xi}}_i(k|\,t)\}_{i\in\mathcal{I}}\right) \tag{28}$$

其中 $\mathcal{P}$ 为规则势函数集合，包含车道保持、速度与舒适性、车距/碰撞风险、行人礼让、交通信号等子项，$\phi_p(\cdot)$ 为对应的标量势函数，w_p 为对应权重，进一步地，可以将各势函数在某一预测步组织成特征向量 $h_{\text{rule}}(x_{k|t},\{\hat{\xi}_i(k\,|\,t)\})=[\phi_{\text{lane}},\phi_{\text{speed}},\phi_{\text{cf,d}},\phi_{\text{cf,ttc}},\phi_{\text{ped}},\phi_{\text{sig}},\ldots]^\top$，并引入规则权重与超参数向量 $\theta_{\text{rule}}=[w_{\text{lane}},w_{\text{speed}},w_{\text{cf,d}},w_{\text{cf,ttc}},w_{\text{ped}},w_{\text{sig}},\ldots]^\top$，则式(28) 可简写为线性形式：

$$\Phi_{\text{rule}}=\theta_{\text{rule}}^\top h_{\text{rule}} \tag{29}$$

由此，将所有规则与舒适性需求都被投射为一组固定结构的特征，再由少量带物理意义的权重进行组合，便于跨场景直接调整或通过学习方法自动标定，下面分别给出各类势函数的具体形式。

1) 车道保持与姿态一致性势场

为了将全局坐标系下的预测轨迹 $\hat{\xi}_i(k\,|\,t)$ 与自车状态 $\mathbf{x}_{k|t}$ 投影至 B 样条参考线 $r(s)$ 所定义的 Frenet 坐标系中，本文首先建立如下数学映射关系：自车当前投影弧长 $s_{k|t}$ 与横向偏移 $d_{k|t}$ 定义为：

$$s_{k|t}=\arg\min_s \| p_{k|t}-r(s)\|_2 \tag{30}$$

$$d_{k|t}=(p_{k|t}-r(s_{k|t}))^\top \mathbf{n}(s_{k|t}) \tag{31}$$

其中 $p_{k|t}=(x_{k|t},y_{k|t})^\top$ 为自车位置，$\mathbf{n}(s)$ 为参考线对应位置的单位法向量。同理，周车 i 在预测步 k 的投影弧长记为 $s_{i,k|t}$。

在车道保持与姿态一致性方面，将 B 样条参考线定义的 Frenet 坐标系作为几何基准，记自车在第 k 步的横向偏移为 d_k，车辆航向角为 ψ_k，参考线切向角为 $\psi_{\text{ref},k}$。横向偏移的二次惩罚促使车辆在车道中心附近行驶，航向误差的二次惩罚则鼓励车辆姿态与参考线切向方向保持一致。车道保持与姿态一致性势函数采用二次形式:

$$\phi_{\text{lane}}(x_{k|t})=d_k^2+\alpha_\psi(\psi_k-\psi_{\text{ref},k})^2 \tag{32}$$

其中 $\alpha_\psi>0$ 为姿态误差权重。该项与 B-spline 走廊约束共同作用：一方面通过几何硬约束限制车辆在车道边界

内行驶，另一方面通过势场代价鼓励车辆靠近车道中心且姿态与道路方向一致，从而在安全裕度与行驶舒适性之间提供柔性的调节空间。

2) 速度、舒适性与避障势场

在速度与舒适性方面，引入综合考虑道路限速、前车交通流状况和交通信号的参考纵向速度，并以自车当前速度与参考速度的偏差构造速度势函数。同时，通过对纵向加速度和 jerk 的二次惩罚刻画乘坐舒适性的要求。设 $\bar{v}_k$ 为结合道路限速、前车状态和交通信号得到的参考纵向速度，v_k 为自车当前纵向速度，a_k 为纵向加速度，j_k 为 jerk。速度与舒适性势函数为:

$$\phi_{\text{speed}}(x_{k|t}, u_{k|t}) = (v_k - \bar{v}_k)^2 + \alpha_a a_k^2 + \alpha_j j_k^2 \tag{33}$$

其中 α_a, α_j 控制加速度与 jerk 对舒适性的影响。通过调整 $\bar{v}_k$ 的生成逻辑，可以在“充分利用限速”和“提前减速避让”之间灵活权衡。

在车距与碰撞风险方面，本文将基于距离和 TTC 的风险势场进行显式分解和组合。沿参考线方向定义自车与前车或潜在碰撞对象的相对距离，并在安全距离附近构造反比型距离势函数，以反映空间裕度的变化；引入基于相对距离和相对速度计算的 TTC 指标，在 TTC 接近最低安全阈值时显著提高惩罚强度，以反映时间裕度的变化。距离势场与 TTC 势场通过加权叠加共同构成车距相关代价，使空间安全裕度和时间安全裕度可以分别调节，从而在密集车流、低速拥堵和高速跟车等不同工况下实现更细致的风险控制。

此外，为了在风险场中显式考虑预测不确定性，本文通过 IGPR 提供的实时方差 $\sigma_{i,k|t}$ 动态调整惩罚边界。 针对前车或潜在碰撞对象，记沿参考线方向的相对距离为 $S_{i,k}$，其明确定义为自车与周车在参考线上投影弧长的差值，即 $S_{i,k} = s_{i,k|t} - s_{k|t}$。 允许的最小安全距离为 $d_{safe,i,k}$,自车速度为 $v_{k|t}$，目标车速度为 $v_{i,k|t}$，相对速度：

$$\Delta v_{i,k|t} = v_{k|t} - v_{i,k|t} \tag{34}$$

基于此定义 TTC 估计：

$$\text{TTC}_{i,k} = \begin{cases} \dfrac{s_{i,k}}{\max(\Delta v_{i,k}, \varepsilon)}, & \Delta v_{i,k} > 0 \\ +\infty, & \Delta v_{i,k} \le 0 \end{cases} \tag{35}$$

其中 $\varepsilon > 0$ 避免除零，当自车相对目标存在逼近趋势时，$\text{TTC}_{i,k}$ 反映在当前相对速度不变条件下的剩余时间裕度。

空间距离势场采用反距离型结构，对接近最小安全距离时的风险进行放大：

$$\phi_{\text{cf,d},i} = \begin{cases} \left(\dfrac{1}{s_{i,k} - d_{\text{safe},i,k}} \right)^2, & s_{i,k} > d_{\text{safe},i,k} \\ \Lambda_{\text{d}}, & s_{i,k} \le d_{\text{safe},i,k} \end{cases} \tag{36}$$

其中为 $d_{\text{safe},i,k}$ 基于车速等因素设定的最小安全距离，Λ_{d} 为饱和惩罚，对应的 TTC 势场为：

$$\phi_{\text{cf,ttc},i} = \begin{cases} \left(\dfrac{1}{\text{TTC}_{i,k} - T_{\text{safe}}} \right)^2, & \text{TTC}_{i,k} > T_{\text{safe}} \\ \Lambda_{\text{ttc}}, & \text{TTC}_{i,k} \le T_{\text{safe}} \end{cases} \tag{37}$$

其中 T_{safe} 为最小安全 TTC 阈值，Λ_{ttc} 为饱和惩罚。距安全边界越近，两类势函数的惩罚越强。

综合两者，对前车和静态障碍构造整体车距/碰撞势场：

$$\phi_{\mathrm{cf}}(x_{k|t},\{\hat{\xi}_i(k\,|\,t)\})=\sum_{i\in\mathcal{I}_{\mathrm{front}}}(\beta_{\mathrm{d}}\phi_{\mathrm{cf,d},i}+\beta_{\mathrm{ttc}}\phi_{\mathrm{cf,ttc},i}),\qquad(38)$$

其中β_{d}, β_{ttc} 为权重，用于分别调节“空间安全裕度”和“时间安全裕度”的相对权重。在统一 OCP 中既关注空间，也关注时间。

3) 行人礼让与交通信号势场

在行人礼让与交通信号遵守方面，针对靠近人行横道或路口区域的场景，对于行人，记其预测位置与自车轨迹之间的最近距离为$d_{\mathrm{ped},i,k}$.定义指数型礼让势场：

$$\phi_{\mathrm{ped},i}(x_{k|t},\hat{\xi}_i(k\,|\,t))=\exp(-\beta_{\mathrm{ped}}d_{\mathrm{ped},i,k})\qquad(39)$$

其中$\beta_{\mathrm{ped}}>0$控制礼让范围。该势函数在行人与自车轨迹存在潜在交叉时迅速i增大，鼓励系统提前减速或等待；当距离较大时惩罚趋于零，避免过度保守。

交通信号势场则结合红灯剩余时间与自车到停止线距离，当按照当前速度无法在红灯结束前安全通过时，对继续加速或不减速的行为附加较大代价，从而促使系统提前采取减速和停车策略。设红灯或禁止通行相位剩余时间为$T_{\mathrm{red},k}$，自车到停止线的弧长距离为$s_{\mathrm{stop},k}$，则定义：

$$\phi_{\mathrm{sig}}(x_{k|t})=\gamma_{\mathrm{sig}}\left[\max\left(0,\frac{s_{\mathrm{stop},k}}{v_k+\varepsilon}-T_{\mathrm{red},k}\right)\right]^2\qquad(40)$$

其中$\gamma_{\mathrm{sig}}>0$为权重，$\varepsilon>0$为避免除零的常数。当按当前速度无法在红灯结束前安全通过时，该项迅速增大，引导 MPC 提前减速或停车；而在绿灯或可安全通过的黄灯阶段，该势函数基本不发挥作用，从而避免过度保守。

4) 总函数

综合上述势函数，预测步k的规则层代价可写为：

$$\Phi_{\mathrm{rule}}(x_{k|t},\{\hat{\xi}_i(k\,|\,t)\})=w_{\mathrm{lane}}\phi_{\mathrm{lane}}+w_{\mathrm{speed}}\phi_{\mathrm{speed}}+w_{\mathrm{cf}}\phi_{\mathrm{cf}}+w_{\mathrm{ped}}\sum_{i\in\mathcal{I}_{\mathrm{ped}}}\phi_{\mathrm{ped},i}+w_{\mathrm{sig}}\phi_{\mathrm{sig}},\qquad(41)$$

并通过式(19) 统一嵌入综合性能指标$J_t(\mathbf{X}_t,\mathbf{U}_t,\mathbf{\Lambda}_t)$中。所有规则相关因素都被统一投射到固定结构的特征向量h_{rule}上，再由具有明确物理意义的权重θ_{rule}进行组合。代价函数在整个预测时域通过求和方式累积，并与轨迹跟踪代价和控制能量代价共同构成统一 OCP 的性能指标。与原始规则势场相比，本文规则层在结构上更加统一，参数化更加显式，尤其是在距离与 TTC 势场的协同建模方面更加清晰，从而既保持了原始 APF 引导的直观性和可解释性，又显著增强了跨场景的可调性和工程上的可标定性。

D. 基于对偶变量的精确避障约束

在复杂的城市道路场景中，碰撞规避约束的构建面临着几何精确性与求解实时性之间的核心矛盾。传统的圆盘覆盖法虽然计算简单，但在狭窄空间中过于保守，容易导致无解；而基于混合整数规划（MILP）的多边形建模虽然精确，但引入了大量二进制变量，导致计算复杂度呈指数级增长，难以满足车载计算平台的实时性要求。

为了解决上述问题，本文采用基于凸集分离定理与强对偶理论的 OBCA 方法 [37, 38]，采取分层建模策略：在主 NLP (Nonlinear Programming) 优化层中，采用基于强对偶理论的精确几何约束以消除保守性；而简化的顶点-半空间近似仅作为上层 QP 预规划中的线性化手段，用于生成初值。本节重点阐述直接进入主 OCP 命题的连续代数约束组构建过程 。

1) 自车与障碍物的几何建模

首先，为了精确描述车辆的矩形轮廓，我们将自车定义为车体坐标系下的凸集 $\mathcal{E}$：

$$\mathcal{E} = \{y \in \mathbb{R}^2 \mid Gy \le g\}, \quad G \in \mathbb{R}^{n_e \times 2}, g \in \mathbb{R}^{n_e} \qquad (42)$$

其中 $n_e = 4$ 对应矩形的四条边，G 和 g 为由车辆长 L 和宽 W 决定的几何参数矩阵与向量，这种表示法允许我们在离线阶段预计算车辆的几何参数矩阵。

对于环境中的第 i 个静态或动态障碍物，我们将其在预测步 k 的几何形状描述为世界坐标系下的凸多面体 $\mathcal{O}_{i,k}$：

$$\mathcal{O}_{i,k|t} = \{z \in \mathbb{R}^2 \mid A_{i,k|t} z \le b_{i,k|t}\}, \quad A_{i,k|t} \in \mathbb{R}^{n_{i,k} \times 2}, b_{i,k|t} \in \mathbb{R}^{n_{i,k}} \qquad (43)$$

自车在全局坐标系中的实际占用区域随其状态变化。自车位姿由状态 $x_{k|t}$ 给出，包含位置 $p_{k|t} \in \mathbb{R}^2$ 与航向角 $\psi_{k|t}$。定义旋转矩阵为：

$$R(\psi) = \begin{bmatrix} \cos\psi & -\sin\psi \\ \sin\psi & \cos\psi \end{bmatrix} \qquad (44)$$

则自车在时刻 k 占用的空间集合可表示为:

$$\mathcal{E}(p_{k|t}, \psi_{k|t}) = \{R(\psi_{k|t}) y + p_{k|t} \mid y \in \mathcal{E}\} \qquad (45)$$

该集合描述了通过对车体坐标系下的凸集 $\mathcal{E}$ 施加旋转变换和平移向量后，自车在全局空间中的实际投影。这种精确的几何表达将被直接应用于主 OCP 的对偶约束构建中，以确保避障的精细化.

2) 对偶约束的构建与松弛

直接计算两个凸集 $\mathcal{E}(p_k, \psi_k)$ 与 $\mathcal{O}_{i,k}$ 之间的欧氏距离是一个非光滑且非凸的优化问题。根据强对偶理论 [37]，两个凸集不相交（即最小距离大于安全阈值 d_{safe}）的充要条件是存在一组对偶变量 $\mu_{i,k} \in \mathbb{R}^{n_e}, \lambda_{i,k} \in \mathbb{R}^{n_{i,k}}$,使得它们满足 Karush-Kuhn-Tucker (KKT) 条件。

基于此，本文将复杂的几何不相交条件转化为如下连续且几乎处处可微的代数约束组，直接嵌入主 OCP 框架中：

$$\begin{cases} -g^\top \mu_{i,k|t} + (A_{i,k|t} p_{k|t} - b_{i,k|t})^\top \lambda_{i,k|t} \ge d_{safe} - s_{i,k|t} \\ G^\top \mu_{i,k|t} + R(\psi_{k|t})^\top A_{i,k|t}^\top \lambda_{i,k|t} = 0 \\ \| A_{i,k|t}^\top \lambda_{i,k|t} \|_2 \le 1 \\ \mu_{i,k|t} \ge 0, \lambda_{i,k|t} \ge 0, s_{i,k|t} \ge 0 \end{cases} \qquad (46)$$

上述约束组被定义为硬约束集合 $\mathcal{C}_{poly}$ 嵌入主 OCP 中。该约束组具有明确的物理含义：第一行不等式通过对偶映射保证了分离超平面间的距离满足安全要求；第二行等式则确立了分离超平面的法向量在自车坐标系与世界坐标系下的一致性。

为了提高数值求解的鲁棒性，我们在式 (46) 中引入了非负松弛变量 $s_{i,k|t}$。在实际优化过程中，硬约束可能因传感器噪声或极端工况导致由于初始位置不可行（Infeasible Start）而求解失败。通过在目标函数中对 $s_{i,k|t}$ 施加较大的惩罚权重 w_{slack}，将硬约束转化为软硬结合的形式：在可行域内严格保证 $s_{i,k}=0$ 以确保无碰撞；在极端不可行区域允许微小侵入以维持求解器的收敛性，从而显著提升系统的鲁棒性。

E. 含多边形碰撞约束的混合 QP 热启动

由于本文提出的统一 OCP 框架耦合了非线性车辆动力学模型与高度非凸的旋转避障约束，其解空间在复杂城市工况下具有显著的非凸性与多极值特征。若直接采用冷启动策略，非线性规划 (NLP) 求解器极易陷入局部极小值，或因初始位置不可行而导致在线收敛失败 。为了满足城市自动驾驶任务对实时运行与收敛鲁棒性的要求，本文设计了 “Warm-start via QP Pre-planning” 分层求解架构。

核心在于对车辆动力学与几何避障约束进行双重凸化简化，以构建计算高效的凸二次规划 (QP) 子问题 。在动力学简化方面，本文不直接处理复杂的非线性状态转移方程，而是将其沿 B 样条平滑后的参考路径进行一阶线性化简化，构建时变线性系统。在几何约束简化方面，采用顶点-半空间模型替代主问题中复杂的对偶变量约束，通过固定参考航向角并将自车轮廓简化为四个顶点，将非凸的避障条件转化为关于位置变量的线性不等式。

此简化预规划层的目的并非生成高精度的最终执行轨迹，而是为了在毫秒级时间内产出一条在几何上局部可行、动力学上合理的粗糙初值。该初值作为导航信号，引导主 NLP 求解器快速进入非凸可行域的强吸引区（Strong Attraction Region），这种分层映射机制使得主 OCP 能够在保证多边形碰撞精确建模的前提下，大幅降低平均迭代次数与求解耗时，从而显著提升了 MP-UBPC 框架在复杂动态场景下的实时运行稳定性。

1) 动力学与几何约束的凸化近似

QP 问题的核心在于保证所有约束的线性或凸性。为此，我们对系统进行了以下两个维度的线性化处理：

（1）动力学模型的时变线性化：在 B 样条平滑后的参考路径附近，我们将非线性车辆动力学方程 $x_{k+1}=f(x_k,u_k)$ 沿参考轨迹展开，得到时变线性系统：

$$\tilde{x}_{k+1}=A_k\tilde{x}_k+B_k\tilde{u}_k+c_k \tag{47}$$

其中，$A_k=\dfrac{\partial f}{\partial x}\Big|_{x_k^{ref},u_k^{ref}}$ 和 $B_k=\dfrac{\partial f}{\partial u}\Big|_{x_k^{ref},u_k^{ref}}$ 分别为非线性动力学在参考点处的雅可比矩阵，c_k 为线性化残差项。这种线性化能够捕捉车辆在特定工作点附近的局部动态特性。

（2）避障约束的顶点-半空间近似： 主问题中的 OBCA 约束因包含旋转矩阵 $R(\psi_k)$ 而无法直接用于 QP。考虑到在短预测时域内，车辆的航向角变化相对平滑，我们在预规划层采用简化的顶点-半空间模型 (Vertex-Halfspace Model) 对几何避障进行局部线性化处理。

设障碍物在预测步的半空间表示为 $A_{i,k|t}z\le b_{i,k|t}$，其中 $a_{i,k|t,j}^{\top}$ 为矩阵 $A_{i,k|t}$ 的第 j 行。$b_{i,k|t,j}$ 为向量 $b_{i,k|t}$ 的第 j 个分量。在 QP 预规划层中，我们固定参考航向 $\psi_{ref,k}$，并将自车用其车体坐标系下的 n_v 个固定顶点 v_q 进行近似，则线性化后的避障约束可表示为：

$$a_{i,k|t,j}^{\top}\left(R(\psi_{ref,k})v_q+p_{k|t}\right)\le b_{i,k|t,j}-d_{safe},\quad \forall q\in\{1,\dots,n_v\},\forall j\in\mathcal{S}_{active} \tag{48}$$

其中，$\mathcal{S}_{active}$ 为通过启发式筛选出的活跃边集合，旨在仅考虑对当前位姿具有潜在威胁的障碍物边界，从而显著降低子问题的约束维度 。

这种近似处理虽然忽略了预测时域内的旋转自由度，但成功将复杂的非凸避障条件转化为了关于位置变量 $p_{k|t}$ 的纯线性不等式。这确保了预规划子问题的严格凸性，使得求解器能够在毫秒级时间内生成一条在几何上局部可行的初值轨迹。

2) 预规划 QP 求解与热启动

基于上述近似，我们构建如下标准 QP 问题：

$$\begin{aligned}
&\min_{\tilde{X},\tilde{U}} \sum_{k=0}^{N-1} (\|\tilde{x}_k - x_k^{ref}\|_{Q_{qp}}^2 + \|\tilde{u}_k\|_{R_{qp}}^2) \\
&\text{s.t. dynamics (45),} \\
&\quad \text{corridor constraints (25),} \\
&\quad \text{linearized avoidance constraints } (46), \\
&\quad \text{bounds}
\end{aligned} \tag{49}$$

其中 Q_{qp} 和 R_{qp} 分别为预规划层的状态跟踪与控制权重矩阵。得益于 QP 问题的稀疏结构，我们可以利用求解器在毫秒级时间内完成求解，得到预规划轨迹 $\tilde{X}^{qp}$ 和控制序列 $\tilde{U}^{qp}$ 。

最终，我们将这一序列作为主 NLP 问题的原始变量初值 (X_{init}, U_{init}) 。由于 $\tilde{X}^{qp}$ 已经在几何上满足了线性的避障约束，它位于主问题非凸可行域的强吸引域内。这种混合热启动策略能降低 NLP 求解器的平均迭代次数，保证 MP-UBPC 框架在复杂动态场景下的实时运行能力。

5. REFERENCES

[1] Paden, B., Čáp, M., Yong, S. Z., Yershov, D., & Frazzoli, E. (2016). A survey of motion planning and control techniques for self-driving urban vehicles. *IEEE Transactions on Intelligent Vehicles, 1*(1), 33-55.

[2] Schwarting, W., Alonso-Mora, J., & Rus, D. (2018). Planning and decision-making for autonomous vehicles. *Annual Review of Control, Robotics, and Autonomous Systems, 1*, 187-210.

[3] Badue, C., Guidolini, R., Carneiro, R. V., Azevedo, P., Cardoso, V. B., Forechi, A., ... & De Souza, A. F. (2021). Self-driving cars: A survey. *Expert Systems with Applications, 165*, 113816.

[4] Yu, S., Hirche, M., Huang, Y., Chen, H., & Allgöwer, F. (2021). Model predictive control for autonomous ground vehicles: A review. *Autonomous Intelligent Systems, 1*(1), 4.

[5] Zhao, J., Wu, Y., Deng, R., Xu, S., Gao, J., & Burke, A. (2025). A survey of autonomous driving from a deep learning perspective. *ACM Computing Surveys, 57*(10), 1-60.

[6] Elallid, B. B., Benamar, N., Hafid, A. S., Rachidi, T., & Mrani, N. (2022). A comprehensive survey on the application of deep and reinforcement learning approaches in autonomous driving. *Journal of King Saud University-Computer and Information Sciences, 34*(9), 7366-7390.

[8] Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A., & Koltun, V. (2017). CARLA: An open urban driving simulator. In *Proceedings of the Conference on Robot Learning* (pp. 1-16). PMLR.

[9] Chib, P. S., & Singh, P. (2024). Recent advancements in end-to-end autonomous driving using deep learning: A survey. *IEEE Transactions on Intelligent Vehicles, 9*(1), 103–118.

[11] Liu, H., Chen, K., Li, Y., Huang, Z., Liu, M., & Ma, J. (2025). UDMC: Unified decision-making and control framework

for urban autonomous driving with motion prediction of traffic participants. *IEEE Transactions on Intelligent Transportation Systems, 26*(5), 5856-5871.

[12] Liu, H., Chen, K., Li, Y., Huang, Z., Duan, J., & Ma, J. (2023). Integrated behavior planning and motion control for autonomous vehicles with traffic rules compliance. In *Proceedings of the IEEE International Conference on Robotics and Biomimetics (ROBIO)* (pp. 1 to 7). IEEE.

[14] Hu, Y., Yang, J., Chen, L., Li, K., Sima, C., Zhu, X., ... & Li, H. (2023). Planning-oriented autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 17853-17862).

[15] Liu, W., Liu, H., Zheng, L., Huang, Z., & Ma, J. (2025). Synergizing decision making and trajectory planning using two-stage optimization for autonomous vehicles. *IEEE Transactions on Vehicular Technology, 74*(4), 5489 to 5503.

[16] Huang, Z., Li, T., Shen, S., & Ma, J. (2024). Integrated decision making and trajectory planning for autonomous driving under multimodal uncertainties: A Bayesian game approach. *arXiv preprint arXiv:2409.13993*.

[19] Reda, M., Onsy, A., Haikal, A. Y., & Ghanbari, A. (2024). Path planning algorithms in the autonomous driving system A comprehensive review. *Robotics and Autonomous Systems, 174*, 104630.

[20] Li, Q., He, H., Hu, M., & Wang, Y. (2025). Spatio-temporal joint trajectory planning for autonomous vehicles based on improved constrained iterative LQR. *Sensors, 25*(2), 512.

[21] Choi, J., Chin, H., Park, H., Kwon, D., Baek, D., & Lee, S.-H. (2025). Safe and efficient trajectory optimization for autonomous vehicles using B-spline with incremental path flattening. *IEEE Transactions on Intelligent Transportation Systems, 26*(2), 1797-1811.

[23] Wu, X., Zhang, Q., Bai, Z., & Guo, G. (2024). A self-adaptive safe A* algorithm for AGV in large-scale storage environment. *Intelligent Service Robotics, 17*(2), 221-235.

[25] Liu, J., Yan, F., Dong, H., Fu, L., & Zhao, Y. (2025). A global and local integrated dynamic path planning algorithm for village roads region. *Proceedings of the Institution of Mechanical Engineers, Part D Journal of Automobile Engineering*.

[27] Rasekhipour, Y., Khajepour, A., Chen, S.-K., & Litkouhi, B. (2017). A potential field-based model predictive path-planning controller for autonomous road vehicles. *IEEE Transactions on Intelligent Transportation Systems, 18*(5), 1255–1267.

[29] Tao, F., Ding, Z., Fu, Z., Li, M., & Ji, B. (2024). Efficient path planning for autonomous vehicles based on RRT* with variable probability strategy and artificial potential field approach. *Scientific Reports, 14*, Article 24698.

[30] Guan, T., Han, Y., Kong, M., Wang, S., Feng, D., & Yang, W. (2025). An improved artificial potential field with RRT* algorithm for autonomous vehicle path planning. *Scientific Reports, 15*, Article 16982.

[32] Xia, T., Chen, H., Yang, J., & Guo, Z. (2024). Geometric field model of driver's perceived risk for safe and human-like trajectory planning. *Transportation Research Part C: Emerging Technologies, 159*, 104470.

[33] Guo, W., Luo, J., Song, X., & Li, J. (2025). A crash-injury-aware driving safety field for real-time risk assessment and its application in autonomous vehicle motion planning. *Accident Analysis & Prevention, 222*, 108224.

[34] Wang, Z., Lu, G., Tan, H., & Liu, M. (2024). A risk-field-based motion planning method for multi-vehicle conflict scenario. *IEEE Transactions on Vehicular Technology, 73*(1), 310-322.

[35] Niu, J., et al. (2024). Dynamic traffic safety risk assessment in road tunnel entrance zone based on drivers' psychophysiological perception states: Methodology and case study insights. *Tunnelling and Underground Space Technology, 147*, 105677.

[36] Zhang, J., & Fu, W. (2025). An integrated framework for obstacle avoidance path planning and tracking of autonomous vehicles considering risk potential fields. *Robotics and Autonomous Systems, 194*, 105153.

[37] Zhang, X., Liniger, A., & Borrelli, F. (2021). Optimization-based collision avoidance. *IEEE Transactions on Control Systems Technology, 29*(3), 972–983.

[38] Zhang, X., Liniger, A., Sakai, A., & Borrelli, F. (2018). Autonomous parking using optimization-based collision avoidance. In *Proceedings of the IEEE Conference on Decision and Control (CDC)* (pp. 4327–4332). IEEE.

[39] He, R., Zhou, J., Jiang, S., Wang, Y., Tao, J., Song, S., ... & Luo, Q. (2021). TDR-OBCA: A reliable planner for autonomous driving in free-space environment. In *Proceedings of the American Control Conference (ACC)* (pp. 2927–2934).

IEEE.

[40] Zhang, X., Yang, B., Pei, X., & Lu, S. (2023). Trajectory planning based on spatio-temporal reachable set considering dynamic probabilistic risk. *Engineering Applications of Artificial Intelligence, 123*(Part A), 106291.

[41] Marcucci, T., Petersen, M., von Wrangel, D., & Tedrake, R. (2023). Motion planning around obstacles with convex optimization. *Science Robotics, 8*(84), eadi7843.

[42] Wang, Y., & Boyd, S. (2010). Fast model predictive control using online optimization. *IEEE Transactions on Control Systems Technology, 18*(2), 267–278.

[43] Zhang, Z., Zhao, Q., & Dai, F. A. (2023). A warm start strategy in interior point methods for shrinking horizon model predictive control with variable discretization step. *IEEE Transactions on Automatic Control, 68*(6), 3830-3837.

[44] Hose, H., Köhler, J., Zeilinger, M. N., & Trimpe, S. (2025). Approximate nonlinear model predictive control with safety-augmented neural networks. *IEEE Transactions on Control Systems Technology, 33*(6), 2490-2497.

[45] Mak, T. W. K., Chatzos, M., Tanneau, M., & Hentenryck, P. V. (2023). Learning regionally decentralized AC optimal power flows with ADMM. *IEEE Transactions on Smart Grid, 14*(6), 4863-4876.

[46] Wang, R., Li, H., Liang, B., Shi, Y., & Xu, D. (2024). Policy learning for nonlinear model predictive control with application to USVs. *IEEE Transactions on Industrial Electronics, 71*(4), 4089-4097.

[47] Codevilla, F., Müller, M., López, A., Koltun, V., & Dosovitskiy, A. (2018). End-to-end driving via conditional imitation learning. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)* (pp. 1–9). IEEE.

[48] Shao, H., Wang, L., Chen, R., Li, H., & Liu, Y.T. (2022). Safety-Enhanced Autonomous Driving Using Interpretable Sensor Fusion Transformer. *Conference on Robot Learning. (CoRL)*.

[49] Jia, X., Wu, P., Chen, L., Xie, J., He, C., Yan, J., & Li, H. (2023). Think twice before driving Towards scalable decoders for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

[50] Li, B., Ouyang, Y., Li, L., & Zhang, Y. (2022). Autonomous driving on curvy roads without reliance on Frenet frame: A Cartesian-based trajectory planning method. *IEEE Transactions on Intelligent Transportation Systems, 23*(9), 15729-15741.

[51] Guan, Y., Ren, Y., Sun, Q., Li, S. E., Ma, H., Duan, J., Dai, Y., & Cheng, B. (2023). Integrated decision and control Toward interpretable and computationally efficient driving intelligence. IEEE Transactions on Cybernetics, 53(2), 859 to 873.

[52] Eiras, F., Hawasly, M., Albrecht, S. V., & Ramamoorthy, S. (2022). A two-stage optimization-based motion planner for safe urban driving. *IEEE Transactions on Robotics, 38*(2), 822-834.

[53] Lim, W., Lee, S., Sunwoo, M., & Jo, K. (2021). Hybrid trajectory planning for autonomous driving in on-road dynamic scenarios. *IEEE Transactions on Intelligent Transportation Systems, 22*(1), 341-355.

[54] Aasi, E., Cai, M., Vasile, C. I., & Belta, C. (2025). A two level control algorithm for autonomous driving in urban environments. *IEEE Transactions on Intelligent Transportation Systems, 26*(1), 410-424.

[55] Ge, Q., Sun, Q., Li, S. E., Zheng, S., Wu, W., & Chen, X. (2021). Numerically stable dynamic bicycle model for discrete-time control. In *Proceedings of the IEEE Intelligent Vehicles Symposium Workshops (IV Workshops)* (pp. 128–134). IEEE.